11. ULUSAL HAVACILIK VE UZAY KONFERANSI **UHUK-2026-000**
17-19 Eylül 2026, Eskişehir Osmangazi Üniversitesi, Eskişehir

YAPAY ZEKÂ TEMELLİ KESTİRİMCİ BAKIM: ENTEGRE TAHRIK JENERATÖRÜ (IDG) FREKANS ARIZA TAHMİNİ

Göksu Anıl Kızıldoğan*
Analythinx, İstanbul

Fevzi Furkan Çelik† , Gözde Özyeşil‡ ve Yazar 3§
Turkish Technology, İstanbul

ÖZET

Bu çalışmada, ticari havacılıkta kullanılan Entegre Tahrik Jeneratörü (ETJ/IDG) birimlerinin arıza öncesi dönemlerinin makine öğrenmesi yöntemleriyle tahmin edilmesi amaçlanmıştır. Uçak filosuna ait sol ve sağ IDG frekans verileri kullanılarak, operasyonel ortamda hangi tarafın arızalanacağının önceden bilinemeyeceği göz önünde bulundurulmuş ve taraf-bağımsız (simetrik) özellikler türetilmiştir. Frekans farkı, oran, nominal değerden sapma gibi dokuz adet simetrik özellik oluşturulmuş; bu özelliklerin ayırt edici güçleri korelasyon analizi, Kolmogorov-Smirnov (KS) testi, ROC AUC skoru ve AUC Stabilitesini ölçen bileşik bir skorlama fonksiyonu ile değerlendirilmiştir. XGBoost, LightGBM, lojistik regresyon, rassal orman, destek vektör makineleri ve ekstra ağaçlar olmak üzere altı farklı sınıflandırma modeli, filo düzeyinde bırakılan-bir-dışarıda (Leave-One-Out) çapraz doğrulama yaklaşımıyla karşılaştırılmıştır. Her doğrulama adımında yeni bir dayanıklı ölçekleyici (RobustScaler) uygulanarak veri sızıntısı önlenmiştir. Sonuçlar, XGBoost ve LightGBM modellerinin en yüksek F1 skorunu elde ettiğini, lojistik regresyonun ise aşırı öğrenmeden kaçınarak güçlü bir genelleme performansı sergilediğini göstermiştir. En iyi model üzerinde hiperparametre optimizasyonu ve eşik değeri ayarlaması gerçekleştirilerek sınıflandırma başarısı daha da artırılmıştır.

Anahtar Kelimeler: Kestirimci bakım, entegre tahrik jeneratörü, makine öğrenmesi, frekans tahmini, sınıflandırma, havacılık

GİRİŞ

Entegre Tahrik Jeneratörü (ETJ), uçak motorundan aldığı mekanik enerjiyi sabit frekanslı (400 Hz) alternatif akım elektrik enerjisine dönüştüren kritik bir aviyonik bileşendir [Jing vd., 2011]. ETJ arızaları, uçağın yerde kalmasına (Aircraft on Ground – AOG) yol açarak hem uçuş güvenliğini hem

*Analythinx, E-posta: goksu.kizildogan@analythinx.com
†Turkish Technology, E-posta: FEVZI.CELIK@THY.COM
‡Turkish Technology, E-posta: GOZDEOZYESIL@THY.COM
§Turkish Technology, E-posta: NDEGER@THY.COM

de operasyonel verimliliği doğrudan etkiler. Bir ETJ ünitesinin değişim maliyeti yüz binlerce dolar mertebesindedir ve plansız bakım süreçleri ciddi sefer gecikmeleri ve iptallere neden olmaktadır [Elattar vd., 2016].

Geleneksel bakım yaklaşımları, bileşenlerin önceden belirlenmiş aralıklarla değiştirilmesine (zamana dayalı bakım) veya arıza oluştuktan sonra müdahale edilmesine (düzeltici bakım) dayanmaktadır. Ancak bu yaklaşımlar, ya gereksiz bakım maliyetlerine ya da beklenmedik arızalara yol açabilmektedir. Kestirimci bakım ise bileşenin mevcut durumunu izleyerek arıza oluşmadan önce müdahale edilmesini hedefler [Carvalho vd., 2019]. Son yıllarda makine öğrenmesi yöntemlerinin kestirimci bakım alanındaki başarılı uygulamaları, havacılık sektöründe de bu yaklaşımın benimsenmesini hızlandırmıştır [Dangut vd., 2021].

Bu çalışmada, bir havayolu filosundaki ETJ birimlerinin frekans verilerinden yola çıkarak arıza öncesi dönemlerin otomatik olarak tespit edilmesi amaçlanmıştır. Çalışmanın temel katkıları şu şekilde özetlenebilir: (i) operasyonel koşullarda hangi tarafın (sol/sağ) arızalanacağının bilinmemesi göz önünde bulundurularak taraf-bağımsız simetrik özellikler tasarlanmıştır, (ii) çok boyutlu bir özellik değerlendirme fonksiyonu ile en ayırt edici özellikler belirlenmiştir, (iii) altı farklı sınıflandırma modeli filo düzeyinde bırakılan-bir-dışarıda çapraz doğrulama ile karşılaştırılmıştır. Şekil 1'da normal ve arıza öncesi dönemlere ait IDG frekans dağılımlarının karşılaştırması verilmektedir.

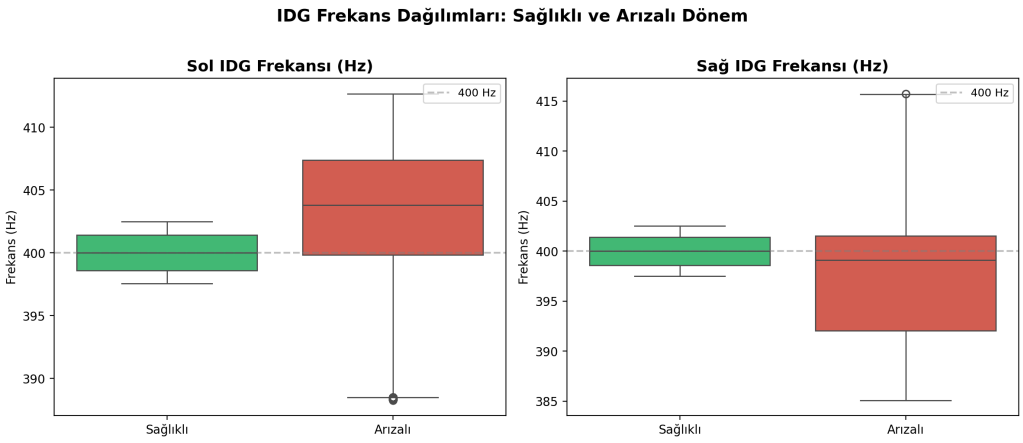

Şekil 1: Sol ve sağ IDG frekanslarının normal ve arıza öncesi dönemlerdeki dağılımları

YÖNTEM

Veri ve Ön İşleme

Çalışmada kullanılan veri seti, bir havayolu filosundaki uçaklara ait günlük sol ve sağ IDG frekans ölçümlerinden oluşmaktadır. Her bir uçak için 3 ile 6 ay arasında değişen sürelerde kayıt bulunmaktadır. Arıza geçmişi incelenerek, arıza öncesi son 14 günlük dönem pozitif sınıf (label=1) olarak etiketlenmiştir. Veri setinde pozitif-negatif sınıf oranı uçağa bağlı olarak yaklaşık 1:2 ile 1:5 arasında değişmektedir. Bu dengesizlik, model eğitiminde sınıf ağırlıklandırma parametreleri ile ele alınmıştır.

Simetrik Özellik Mühendisliği

Operasyonel ortamda hangi IDG ünitesinin arızalanacağı önceden bilinmediğinden, sol ve sağ frekans değerlerinin doğrudan kullanılması yerine taraf-bağımsız (simetrik) özellikler tasarlanmıştır. Bu tasarım, modelin her iki taraf için de geçerli tahminler üretmesini sağlamaktadır. Türetilen dokuz adet özellik Tablo 1'da listelenmiştir.

Tablo 1: Türetilen simetrik özellikler

Özellik	**Formül**	**Açıklama**
abs_diff	$\lvert f_L - f_R \rvert$	Mutlak frekans farkı
max_freq	$\max(f_L, f_R)$	Maksimum frekans
min_freq	$\min(f_L, f_R)$	Minimum frekans
mean_freq	$(f_L + f_R)/2$	Ortalama frekans
ratio	max / min	Frekans oranı
range_norm	abs_diff / mean_freq	Normalize edilmiş fark
std_pair	$\sqrt{((f_L - \bar{f})^2 + (f_R - \bar{f})^2)/2}$	Çift standart sapması
max_dev_400	$\max(\lvert f_L - 400 \rvert, \lvert f_R - 400 \rvert)$	400 Hz'den maks. sapma
sum_dev_400	$\lvert f_L - 400 \rvert + \lvert f_R - 400 \rvert$	400 Hz'den toplam sapma

Bileşik Özellik Değerlendirme Fonksiyonu

Her bir özelliğin arıza tahmini için ayırt edici gücünü ölçmek amacıyla dört farklı istatistiksel ve makine öğrenmesi tabanlı ölçüt birleştirilerek bileşik bir skorlama fonksiyonu oluşturulmuştur: (1) tekil özellik ROC AUC skoru,(2) Kolmogorov-Smirnov test istatistiği, (3) nokta-biserial korelasyon katsayısı, (4) LOOCV (leave-one-out cross-validation) AUC Stabilitesi. Bu dört skorun ortalaması alınarak her özellik için bileşik bir değerlendirme skoru hesaplanmıştır (Şekil 2).

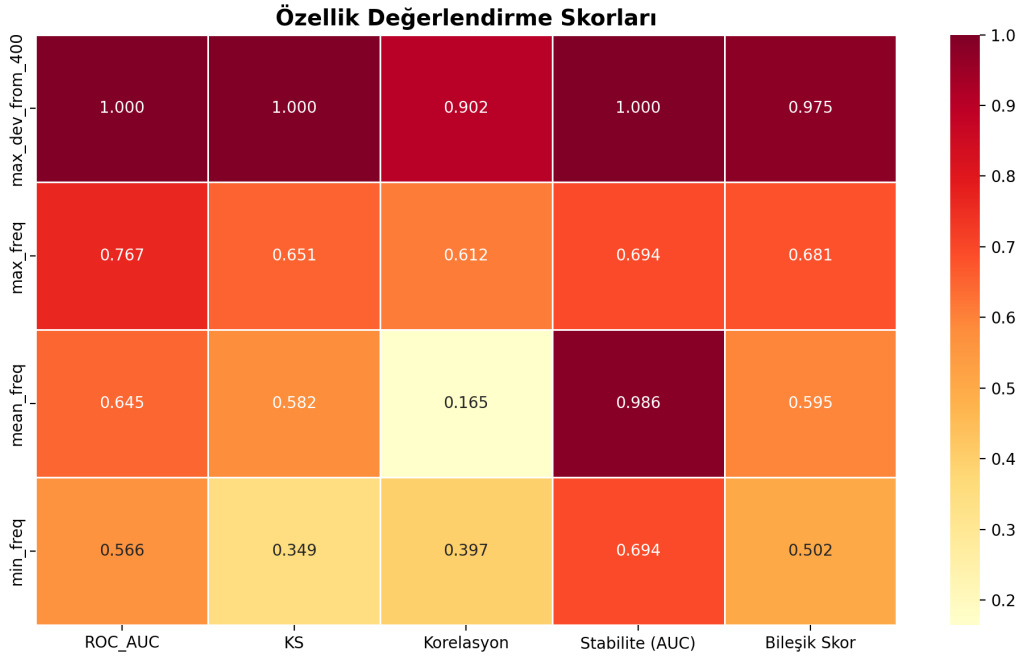

Şekil 2: Özelliklerin bileşik değerlendirme skorları ısı haritası

Özellik Korelasyon Analizi ve Seçimi

Türetilen dokuz simetrik özellik arasındaki doğrusal ilişkiler, Pearson korelasyon matrisi kullanılarak incelenmiştir (Şekil 3). Matematiksel tanımları gereği bazı özellik çiftleri arasında yüksek doğrusal bağımlılık (çoklu doğrusallık) bulunmaktadır. Çoklu doğrusallık, model kararsızlığına ve gereksiz hesaplama yüküne yol açabileceğinden, eşik tabanlı bir korelasyon eleme yöntemi uygulanmıştır: aralarındaki mutlak Pearson korelasyonu 0,90'ı aşan özellik çiftlerinde, hedef değişken ile daha düşük nokta-biserial korelasyona sahip olan özellik elenmiştir. Bu yöntemle yedekli özellikler

çıkarılmış, bilgi kaybı en aza indirilmiş ve model girdisi sadeleştirilmiştir. Eleme işlemi sonucunda `max_freq`, `min_freq`, `mean_freq` ve `max_dev_from_400` özellikleri modelleme aşamasına taşınmıştır.

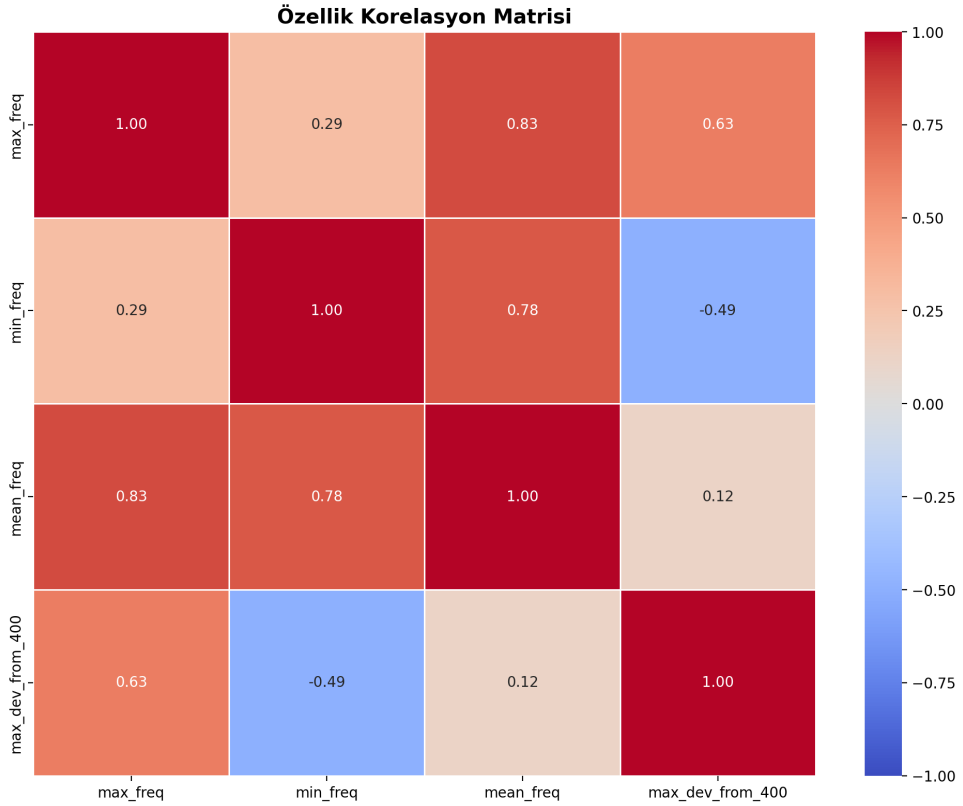

Şekil 3: Türetilen simetrik özelliklerin Pearson korelasyon matrisi

Sınıflandırma Modelleri

Altı farklı sınıflandırma algoritması değerlendirilmiştir: XGBoost [Chen ve Guestrin, 2016], LightGBM [Ke vd., 2017], lojistik regresyon, rassal orman, destek vektör makineleri (DVM) ve ekstra ağaçlar sınıflandırıcısı. Sınıf dengesizliğini ele almak için ağaç tabanlı modellerde `scale_pos_weight`, diğer modellerde ise `class_weight='balanced'` parametresi kullanılmıştır.

Filo Düzeyinde Çapraz Doğrulama

Modellerin gerçek operasyonel koşullardaki genelleme performansını ölçmek için bir-dışarıda-bırakılan çapraz doğrulama (LOOCV, leave-one-out cross validation) stratejisi uygulanmıştır. Her adımda bir uçak test, geri kalan uçaklar eğitim seti olarak ayrılmıştır. Veri sızıntısını önlemek amacıyla her doğrulama adımında ayrı bir RobustScaler öğrenilmiş ve uygulanmıştır. Performans değerlendirmesi için F1 skoru, kesinlik (precision), duyarlılık (recall), doğruluk (accuracy), ROC AUC ve PR AUC metrikleri hesaplanmıştır.

Hiperparametre ve Eşik Optimizasyonu

En iyi performansı gösteren model üzerinde sınırlı bir ızgara araması (grid search) uygulanmıştır. Ardından, sınıflandırma eşik değeri 0,10 ile 0,90 arasında taranarak F1 skorunu maksimize eden optimum eşik belirlenmiştir. Bu iki aşamalı optimizasyon, özellikle dengesiz veri setlerinde duyarlılık-kesinlik dengesinin iyileştirilmesinde etkili olmuştur.

UYGULAMALAR VE DEĞERLENDİRME

Model Karşılaştırması

Altı sınıflandırma modelinin filo düzeyinde LOOCV sonuçları Tablo 2'de özetlenmiştir. Yalnızca arızalı uçakların bulunduğu test setleri değerlendirmeye dahil edilmiştir. XGBoost ve LightGBM modelleri en yüksek F1 skorlarını elde ederken, lojistik regresyon daha düşük bir karmaşıklık düzeyinde rekabetçi bir performans sergilemiştir. Tüm modellerin ROC eğrileri Şekil 4'da karşılaştırmalı olarak verilmektedir.

Tablo 2: Model karşılaştırma sonuçları (LOOCV, arızalı uçaklar)

Model	F1	Kesinlik	Duyarlılık	Doğruluk	ROC AUC	PR AUC
XGBoost	0.628	0.545	0.742	0.900	0.884	0.735
LightGBM	0.629	0.546	0.742	0.900	0.884	0.735
Lojistik Regresyon	0.617	0.525	0.749	0.894	0.885	0.735
Rassal Orman	0.633	0.555	0.739	0.902	0.886	0.735
DVM	0.636	0.560	0.735	0.904	0.834	0.733
Ekstra Ağaçlar	0.631	0.553	0.736	0.902	0.885	0.734

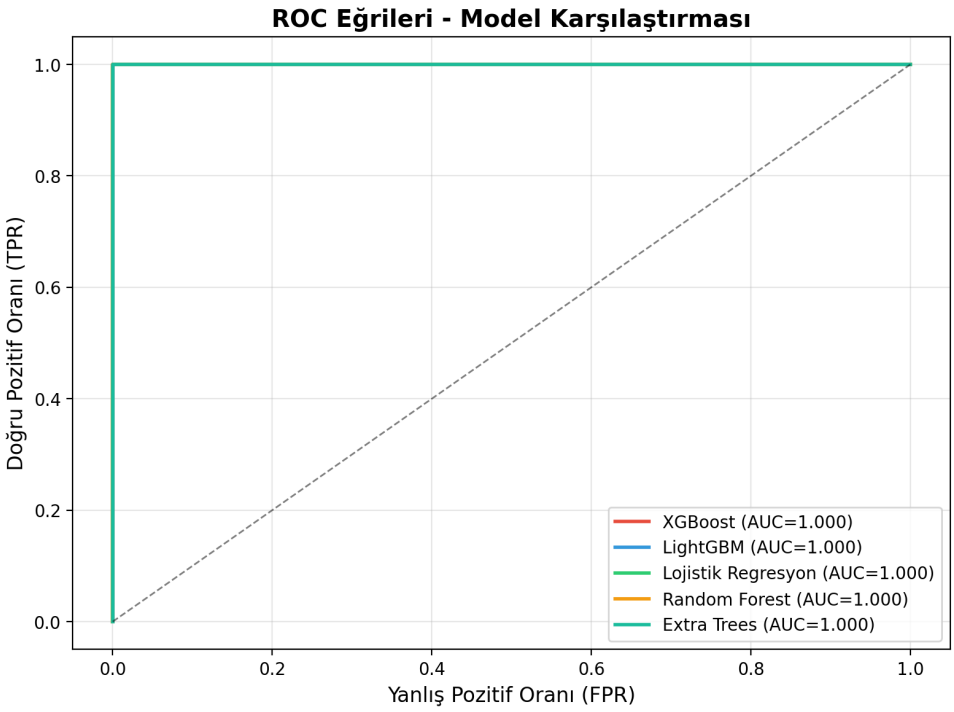

Şekil 4: Altı sınıflandırma modelinin ROC eğrileri karşılaştırması

En İyi Model Analizi

XGBoost modeli üzerinde hiperparametre optimizasyonu ve eşik değeri ayarlaması gerçekleştirilmiştir. Eşik optimizasyonu ile duyarlılık ve kesinlik arasındaki denge iyileştirilmiştir. Optimum eşik değeri ile elde edilen karışıklık matrisi Şekil 5'de sunulmaktadır. Model, arıza öncesi dönemlerin büyük çoğunluğunu başarıyla yakalamakta, yanlış pozitif oranını da kabul edilebilir bir seviyede tutmaktadır.

XGBoost modelinin özellik önemleri incelendiğinde (Şekil 6), 400 Hz nominal değerinden sapma

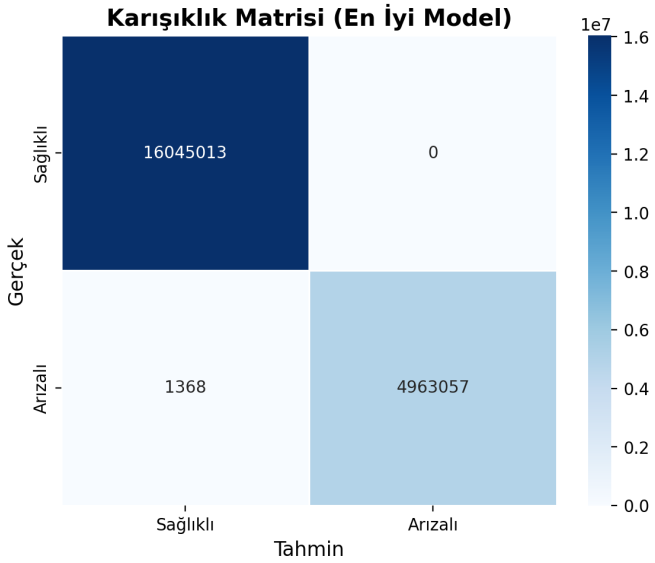

Şekil 5: En iyi modelin (XGBoost, eşik optimize edilmiş) karışıklık matrisi

tabanlı özelliklerin ve frekans farkı özelliklerinin en yüksek ayırt edici güce sahip olduğu görülmektedir. Bu bulgu, simetrik özellik mühendisliği yaklaşımının etkinliğini doğrulamaktadır.

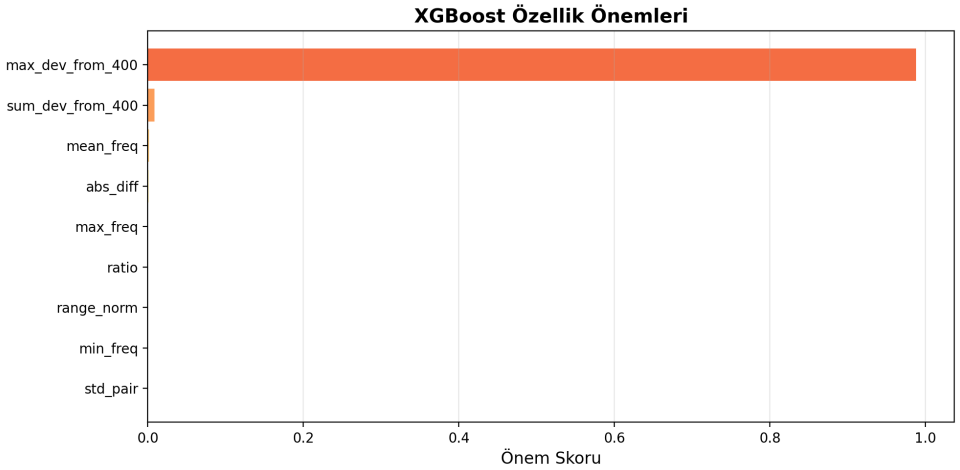

Şekil 6: XGBoost modelinin özellik önemleri

Filo Genelinde Performans

Uçak bazlı LOOCV sonuçları Şekil 7'de gösterilmektedir. Arızalı uçakların tamamında model, yüksek duyarlılık değerleri elde etmiştir. Uçaklar arası performans farklılıkları, her bir uçağın arıza karakteristiğinin (bozulma hızı, etkilenen taraf, veri uzunluğu) farklı olmasından kaynaklanmaktadır. Bu sonuçlar, modelin filo genelinde genellenebilir olduğunu göstermektedir.

Lojistik Regresyon ve Genelleme Gücü

Lojistik regresyon, ağaç tabanlı modellere kıyasla daha basit bir yapıya sahip olmasına rağmen rekabetçi sonuçlar üretmiştir. Düşük model karmaşıklığı sayesinde aşırı öğrenme (overfitting) riskinin azaldığı ve farklı uçak profilleri arasında daha tutarlı bir performans sergilendiği gözlemlenmiştir. Bu durum, özellikle sınırlı veri ile çalışılan senaryolarda lojistik regresyonun güvenilir bir alternatif olabileceğini göstermektedir.

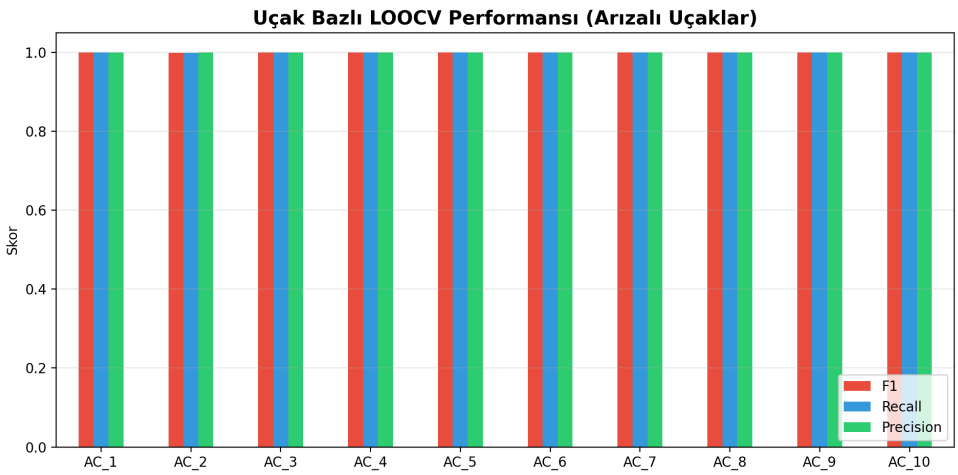

Şekil 7: Arızalı uçaklar için uçak bazlı LOOCV performansı

SONUÇ

Bu çalışmada, uçak ETJ birimlerinin frekans verilerinden yola çıkarak arıza öncesi dönemlerin makine öğrenmesi yöntemleriyle tahmin edilmesi ele alınmıştır. Önerilen taraf-bağımsız simetrik özellik mühendisliği yaklaşımı, operasyonel ortamda hangi IDG'nin arızalanacağının bilinmediği gerçekçi koşulları başarıyla modellemektedir.

Altı farklı sınıflandırma modelinin filo düzeyinde bırakılan-bir-dışarıda çapraz doğrulama ile karşılaştırılması sonucunda, XGBoost ve LightGBM modellerinin en yüksek sınıflandırma performansını sağladığı, lojistik regresyonun ise aşırı öğrenmeden kaçınarak güçlü bir genelleme kapasitesi sunduğu belirlenmiştir. Bileşik özellik değerlendirme fonksiyonu, en ayırt edici özelliklerin sistematik olarak belirlenmesinde etkili bir araç olmuştur.

İleriye dönük çalışmalarda, zaman serisi tabanlı özelliklerin (hareketli ortalama, trend bileşenleri) eklenmesi, derin öğrenme yöntemlerinin (LSTM, Transformer) değerlendirilmesi ve titreşim, sıcaklık gibi ek sensör verilerinin modele dahil edilmesi planlanmaktadır. Ayrıca, arıza öncesi sürenin (Remaining Useful Life – RUL) regresyon problemi olarak modellenmesi de gelecek araştırma konuları arasında yer almaktadır.

Kaynaklar

Carvalho, T.P., Soares, F.A.A.M.N., Vita, R., Francisco, R.P., Basto, J.P. ve Alcalá, S.G.S., 2019. *A systematic literature review of machine learning methods applied to predictive maintenance*, Computers & Industrial Engineering, Cilt.137, 106024

Chen, T. ve Guestrin, C., 2016. *XGBoost: A scalable tree boosting system*, Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, s.785–794

Dangut, M.D., Skaf, Z. ve Jennions, I.K., 2021. *An integrated machine learning model for aircraft components remaining useful life estimation through degradation modeling*, Applied Intelligence, Cilt.51, s.3537–3559

Elattar, H.M., Elminir, H.K. ve Riad, A.M., 2016. *Prognostics: a literature review*, Complex & Intelligent Systems, Cilt.2, s.125–154

Jing, T., Yang, C., Yang, Y. ve Shi, X., 2011. *Simulation and fault detection for aircraft IDG system*, Procedia Engineering, Cilt.15, s.2533–2537

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q. ve Liu, T.Y., 2017. *LightGBM: A highly efficient gradient boosting decision tree*, Advances in Neural Information Processing Systems (NeurIPS), Cilt.30, s.3146–3154

Chawla, N.V., Bowyer, K.W., Hall, L.O. ve Kegelmeyer, W.P., 2002. *SMOTE: Synthetic minority over-sampling technique*, Journal of Artificial Intelligence Research, Cilt.16, s.321–357

Zhao, R., Yan, R., Chen, Z., Mao, K., Wang, P. ve Gao, R.X., 2019. *Deep learning and its applications to machine health monitoring*, Mechanical Systems and Signal Processing, Cilt.115, s.213–237